

R^2
0.71

Técnicas de Explicabilidad (XAI)

Aplicadas a la Predicción de Rendimiento Académico

Integrantes: Harold Angulo, Melissa Figallo, Jorge Maldonado, Paula Noboa.

Grupo Nro. 5 - Mayo 2026

Dataset: DS15 – Rendimiento Académico Estudiantil · Modelo: Random Forest Regressor

Agenda

01

Introducción del Problema

¿Qué predice el modelo y por qué importa la explicabilidad?

02

Metodología y Técnicas XAI

SHAP · LIME · Permutation Importance · PDP

03

Análisis Comparativo

Rankings entre técnicas + concordancias y divergencias

04

Conclusiones y Recomendaciones

Límites del modelo, riesgos éticos y próximos pasos

01 Introducción del Problema

Dataset

DS15 — 1.070 estudiantes universitarios, 14 variables académicas y contextuales

Objetivo

Predecir `nota_final` (0–100) antes de que el semestre termine

Modelo

Random Forest Regressor — R^2 0.71 · RMSE 4.8 pts

¿Por qué XAI?

Un modelo con 0.71 de R^2 aún comete errores. Sin explicabilidad, no sabemos en qué casos ni por qué

1.070

estudiantes

12

features finales

71%


varianza explicada (R^2)

4.8 pts

error promedio (RMSE)

02 Metodología — Pipeline de Preprocesamiento

Flujo sin Data Leakage — aplicado antes de cualquier técnica XAI



⚠ REGLA CRÍTICA — Sin Data Leakage: fit() se aplica ÚNICAMENTE sobre X_train. Los pasos 1–3 son limpieza de formato (no estadística) y pueden ejecutarse antes del split. Los pasos 5–7 aprenden estadísticas del dato y DEBEN ejecutarse después del split.

02 Técnicas XAI Aplicadas

T1

SHAP

Shapley Additive Explanations

Alcance: Global + Local · Modelo: RF (TreeExplainer)

Contribución marginal exacta de cada feature por muestra. Garantías matemáticas (eficiencia, simetría, nulidad).

T2

LIME

Local Interpretable Model-agnostic Explanations

Alcance: Local · Modelo: Agnóstico

Aproxima el modelo localmente con una regresión lineal sobre vecindad perturbada. Útil para comunicar casos individuales.

T3

PFI

Permutation Feature Importance

Alcance: Global · Modelo: Agnóstico

Mide degradación del RMSE en test al permutar un feature. Más robusto que la importancia Gini nativa de RF.

T4

PDP


Partial Dependence Plots

Alcance: Global · Modelo: Agnóstico

Efecto marginal promedio de 1 o 2 features sobre la predicción. Ideal para comunicar tendencias a no-técnicos.

02 SHAP — Importancia Global y Explicaciones Locales

Importancia Media |SHAP| por Feature



promedio_examenes_parciales domina

Concentra el 65% de la importancia SHAP total. Efecto casi perfectamente lineal y positivo.

horas_estudio + asistencia_pct

Posiciones 2 y 3. Relación positiva con rendimientos decrecientes a partir de ~30 hrs/semana.

num_reprobadas_previas

Contribución negativa consistente: cada materia reprobada adicional reduce la nota predicha.

Modalidad y tutor

Importancia residual — no determinan la nota una vez controladas las demás variables.

02 Explicaciones Individuales — SHAP Waterfall + LIME

✓ Estudiante de Alto Rendimiento

Valor base: 70.0 → Predicción: 88.2 | Real: 91.0

promedio_exámenes_parciales	+18.4
-----------------------------	-------

asistencia_pct	+3.1
----------------	------

horas_estudio_sem	+2.7
-------------------	------

tutor_asignado	+0.8
----------------	------

num_reprobadas_previas	-0.9
------------------------	------

horas_trabajo_sem	-0.5
-------------------	------

⚠ Estudiante en Riesgo Académico

Valor base: 70.0 → Predicción: 38.5 | Real: 35.2

promedio_exámenes_parciales	-21.3
-----------------------------	-------

num_reprobadas_previas	-4.2
------------------------	------

horas_trabajo_sem	-2.1
-------------------	------

horas_estudio_sem	-1.8
-------------------	------

acceso_internet	+0.6
-----------------	------

tutor_asignado	+0.4
----------------	------

03 Análisis Comparativo — Concordancia entre Técnicas XAI

Feature	SHAP	PFI	Gini-RF	Ridge β	Consens o
promedio_exámenes_parciales	#1	#1	#1	#1	★ #1
horas_estudio_sem	#2	#2	#2	#3	★ #2
asistencia_pct	#3	#3	#3	#2	★ #3
num_reprobadas_previas	#4	#4	#4	#4	★ #4
nivel_socioeconomico	#5	#6	#6	#5	~ #5-6
num_tareas_entregadas	#6	#5	#5	#6	~ #5-6
acceso_internet	#7	#7	#8	#7	~ #7-8

Alta concordancia top-4

Las 4 técnicas ubican los mismos features en las 4 primeras posiciones. Esto valida su relevancia predictiva real.


Divergencia en posiciones 5-6

Gini sobrestima num_tareas vs PFI/SHAP. Efecto conocido de la importancia Gini en features continuos de alta cardinalidad.

Ridge vs RF en asistencia

Ridge otorga más peso a asistencia_pct porque captura mejor la relación lineal parcial con nota_final.

03 Comparación de Modelos — Métricas de Regresión



18.5

Baseline RMSE

El modelo aprende algo útil si supera este umbral

0.92

Ridge R^2 test

Alta linealidad — RF captura las mismas relaciones

0.71

RF R^2 test

Mejor modelo — pero con overfitting leve detectable

3.0

Gap RF (RMSE)

Diferencia train-test (leve overfitting controlado)

04 Riesgos Éticos y de Sesgo — Si se Despliega en Producción

⚠ Variable con peso excesivo

promedio_exámenes_parciales concentra ~65% de la importancia. En semana 1 del semestre, esa variable no existe. El modelo pierde casi toda su capacidad predictiva si se despliega antes de tener parciales.

⚠ Sesgo socioeconómico

nivel_socioeconomico y acceso_internet son features con impacto estadístico. Un sistema de alerta basado en este modelo podría etiquetar sistemáticamente a estudiantes de bajos recursos como 'en riesgo', perpetuando desventajas estructurales (O'Neil, 2016).

⚠ Brecha digital replicada

El modelo aprende que no tener acceso a internet correlaciona con notas bajas. En producción, replicaría esa brecha en lugar de compensarla, discriminando por acceso tecnológico en vez de capacidad académica.

⚠ Falsa objetividad sin error comunicado

$R^2=0.71$ significa que el 29% de la varianza no se explica. Sin comunicar el error, el modelo aparenta certeza científica donde hay incertidumbre real. Decisiones importantes no deben tomarse sin intervalos de confianza.

04 Conclusiones y Recomendaciones

C1

XAI convierte métricas en decisiones

Sin explicabilidad, $R^2=0.71$ es solo un número. Con SHAP y LIME, cada predicción se convierte en un diagnóstico accionable: qué factores protegen a un estudiante y cuáles lo ponen en riesgo.

C2

Convergencia entre técnicas = confianza

Las 4 técnicas coinciden en el ranking del top-4. Esa redundancia intencional es el estándar mínimo para confiar en los resultados de importancia de variables.

C3

El modelo no puede ir solo a producción

Se requiere: (1) segmentar por momento del semestre, (2) medir equidad por grupos, (3) incluir intervalos de confianza, (4) mantener supervisión humana en decisiones con impacto en el estudiante.

04 Próximos Pasos para Implementación Responsable

Corto plazo (1–2 semanas)

- Implementar Pipeline de scikit-learn (ColumnTransformer + Pipeline) para eliminar riesgo de data leakage manual
- Probar XGBoost/LightGBM con SHAP integrado (shap.TreeExplainer es nativo)
- Generar reporte automático con waterfall SHAP por estudiante

Mediano plazo (1–2 meses)

- Segmentar modelo por semana del semestre (sem. 1–4 sin parciales, sem. 8+ con parciales)
- Medir equidad: RMSE desagregado por nivel_socioeconomico, acceso_internet y modalidad
- A/B test: comparar alertas con y sin explicabilidad para medir impacto en intervención docente

Largo plazo (3–6 meses)

- Incorporar retroalimentación de docentes para corregir sesgos identificados
- Evaluar modelo inherentemente interpretable (Lasso, árbol de decisión profundo) como alternativa con XAI nativa
- Establecer protocolo de consentimiento informado y auditoría ética periódica

Gracias

*La explicabilidad no es un lujo estético —
es una condición ética para el ML en contextos educativos.*

4

técnicas XAI
aplicadas

65%

importancia
de 1 feature

4/4

técnicas
concuerdan top-4